



PROPOSAL SKRIPSI

Judul:

Deteksi Lauk Nasi Padang untuk Sistem
Checkout Otomatis dengan Instance Segmentation
menggunakan
YOLOv11

Disusun oleh:

STEVEN
NIM. 535230075

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TARUMANAGARA
2026

Persetujuan

Nama : STEVEN
NIM : 535230075
Program Studi : TEKNIK INFORMATIKA
Judul : Deteksi Lauk Nasi Padang untuk Sistem Checkout
Otomatis dengan Instance Segmentation menggunakan
YOLOv11

Proposal Skripsi ini disetujui untuk diuji

Jakarta, 28-Agustus-2026

Pembimbing:
CHAIRISNI LUBIS, Dra., M.Kom.
NIK/NIP: 10393012

Daftar Isi

1	PENDAHULUAN	1
1.1	Latar Belakang	1
1.2	Rumusan Rancangan	3
1.3	Komponen Perancangan	4
1.4	Spesifikasi Perancangan	5
1.5	Kegunaan Rancangan	6
1.6	Rancangan yang Sudah Dibuat	7
2	LANDASAN TEORETIK	9
2.1	Sistem yang Dirancang	9
2.2	Landasan Teori	11
2.2.1	Nasi Padang	11
2.2.2	<i>Computer Vision</i> dan Citra Digital	13
2.2.3	<i>Instance Segmentation</i>	14
2.2.4	YOLO11-seg	15
2.2.5	Penghitungan Instans dan Perhitungan Total Harga	19
2.2.6	Evaluasi Kinerja Model dan Sistem	20
3	RANCANGAN DAN PEMBUATAN	25
3.1	Rancangan Sistem	25
3.1.1	Perencanaan Sistem	25
3.1.1.1	Pengumpulan Data	26
3.1.1.2	Anotasi Data	29
3.1.1.3	Pembagian Dataset	32
3.1.1.4	Augmentasi Data	33
3.1.2	Analisis Sistem	35

3.1.3	Perancangan Sistem	36
3.1.3.1	Rancangan Pelatihan Model	37
3.1.3.2	Rancangan Proses <i>Checkout</i>	38

Daftar Gambar

2.1	Diagram alur pelatihan dan inferensi sistem <i>checkout</i> otomatis . . .	10
2.2	Contoh penyajian Nasi Padang untuk pelanggan <i>dine-in</i>	12
2.3	Contoh penyajian Nasi Padang untuk <i>take-away</i>	13
2.4	Perbandingan klasifikasi citra, lokalisasi objek, segmentasi semantik, dan <i>instance segmentation</i>	14
2.5	Arsitektur YOLO11-seg	16
3.1	Contoh citra acuan yang digunakan dalam proses pengumpulan data	26
3.2	Contoh proses penyaringan citra oleh program <i>crawler</i>	28
3.3	Ringkasan hasil awal program <i>crawler</i> sebelum pembersihan manual	28
3.4	Proses pembuatan anotasi menggunakan fitur <i>Segment Anything</i> pada CVAT	30
3.5	Proses pembuatan anotasi menggunakan fitur OpenCV <i>Intelligent</i> <i>Scissors</i> pada CVAT	31
3.6	Contoh citra pelatihan hasil augmentasi	34

BAB I

PENDAHULUAN

1.1 Latar Belakang

Restoran Nasi Padang merupakan salah satu jenis rumah makan yang mudah ditemukan di Indonesia. Salah satu karakteristiknya adalah tersedianya berbagai jenis lauk yang dapat dipilih pelanggan, seperti rendang, perkedel, telur dadar, sayur nangka, daun singkong, telur kari, dan sambal. Pada pelayanan konvensional, pelanggan menyampaikan lauk yang diinginkan kepada staf, kemudian staf mengambilkan lauk tersebut untuk pelanggan. Setelah selesai makan, pelanggan menghampiri staf pada bagian pembayaran dan menyebutkan satu per satu jenis serta jumlah lauk yang telah dikonsumsi berdasarkan ingatan pelanggan. Staf kemudian menghitung total harga dari lauk yang disebutkan dan menyampaikan jumlah yang harus dibayarkan kepada pelanggan.

Dalam kondisi jumlah pelanggan yang tinggi, proses pengambilan lauk tersebut dapat menyebabkan pelanggan harus menunggu ketersediaan staf sebelum dapat dilayani. Pada saat yang sama, staf perlu membagi perhatian antara melayani pelanggan *dine-in* dan menangani pesanan lain, termasuk pesanan *take-away*. Kondisi ini dapat menimbulkan antrean pada proses pelayanan dan mengurangi efisiensi kerja staf.

Untuk mengatasi permasalahan tersebut, penelitian ini mengusulkan alternatif pelayanan berupa *self-service* untuk pelanggan *dine-in*. Pada mekanisme ini, pelanggan dapat mengambil dan memilih sendiri lauk yang diinginkan dari lauk yang tersedia, kemudian membawa piring yang telah dipilih ke proses *checkout*. Dengan demikian, pelanggan tidak perlu menunggu staf untuk mengambilkan lauk satu per satu. Penerapan mekanisme *self-service* juga memungkinkan staf untuk

mengurangi aktivitas pelayanan pengambilan lauk *dine-in* sehingga dapat lebih berfokus pada pelayanan lain, khususnya pemenuhan pesanan *take-away*.

Agar mekanisme tersebut dapat diterapkan tanpa mengharuskan staf memeriksa kembali lauk yang dipilih pelanggan secara *self-service*, diperlukan suatu sistem yang mampu mengenali isi piring secara otomatis. Kebutuhan tersebut merupakan salah satu permasalahan yang dapat ditangani menggunakan *Computer Vision*. Pemanfaatan *Computer Vision* dalam analisis makanan telah mencakup berbagai tugas seperti pengenalan, deteksi, dan segmentasi makanan [1].

Dalam beberapa kasus lauk yang terdapat pada satu piring, pengenalan kelas saja belum cukup karena sistem juga perlu membedakan setiap lauk sebagai objek yang terpisah untuk menghitung jumlahnya. Oleh karena itu, penelitian ini menggunakan *instance segmentation*. *Instance segmentation* menghasilkan informasi kelas sekaligus *mask* untuk setiap instans objek sehingga beberapa objek dari kelas yang sama tetap dapat direpresentasikan secara terpisah [2].

Kemampuan tersebut sesuai dengan karakteristik objek makanan yang dapat memiliki bentuk tidak beraturan dan saling menutupi serta dengan kebutuhan sistem *checkout* untuk menghitung setiap instans secara individual [3, 4, 5]. Total pembayaran pada sistem yang dirancang ditentukan berdasarkan jenis dan jumlah lauk, bukan berdasarkan luas area lauk pada citra.

Salah satu model yang digunakan dalam pengembangan *object detection* adalah YOLO (*You Only Look Once*). YOLO dirancang untuk mendeteksi objek dalam citra dengan melakukan lokalisasi dan klasifikasi dalam satu proses inferensi. Seiring perkembangannya, keluarga YOLO tidak hanya digunakan untuk *object detection*, tetapi juga mendukung beberapa tugas *Computer Vision* lainnya, termasuk *image classification* dan *instance segmentation* [6].

YOLO11 merupakan salah satu versi dari keluarga YOLO yang dikembangkan dengan peningkatan pada arsitektur dan efisiensi model. YOLO11 mendukung

beberapa tugas *Computer Vision*, termasuk *instance segmentation*. Untuk tugas tersebut, digunakan varian YOLO11-seg yang menghasilkan informasi kelas dan *pixel mask* untuk setiap objek yang terdeteksi [6, 7]. Output tersebut memungkinkan sistem untuk menentukan batas setiap lauk dan membedakan beberapa lauk sebagai instans yang terpisah sehingga jumlahnya dapat dihitung secara otomatis. Berdasarkan kebutuhan tersebut, YOLO11-seg digunakan sebagai model utama dalam penelitian ini.

Berdasarkan uraian tersebut, penelitian ini merancang *proof-of-concept* sistem *checkout* otomatis yang menyediakan opsi *self-service* bagi pelanggan *dine-in* restoran Nasi Padang. Pelanggan dapat mengambil lauk secara mandiri, kemudian sistem menggunakan YOLO11-seg untuk mendeteksi, melakukan *instance segmentation*, dan menghitung setiap instans lauk pada piring. Hasil tersebut selanjutnya digunakan untuk menghitung total pembayaran berdasarkan harga tetap setiap kelas lauk. Penelitian ini dibatasi pada sembilan kelas, yaitu nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal.

Berdasarkan latar belakang tersebut, penelitian ini mengusulkan judul “Deteksi Lauk Nasi Padang untuk Sistem *Checkout* Otomatis dengan *Instance Segmentation* Menggunakan YOLO11”.

1.2 Rumusan Rancangan

Berdasarkan latar belakang yang telah diuraikan, penelitian ini berfokus pada perancangan sistem *checkout* otomatis yang memanfaatkan *instance segmentation* untuk mengenali dan menghitung lauk Nasi Padang. Rumusan rancangan dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan melatih model *instance segmentation* menggunakan arsitektur YOLO11-seg agar mampu mendeteksi dan

melakukan segmentasi terhadap sembilan kelas lauk Nasi Padang serta menghasilkan prediksi setiap instans objek secara individual?

2. Bagaimana mengevaluasi performa YOLO11-seg dalam mendeteksi, melakukan segmentasi, dan menghitung instans lauk Nasi Padang berdasarkan hasil pengujian model?
3. Bagaimana merancang alur integrasi hasil deteksi dan *instance counting* dari YOLO11-seg dengan sistem penetapan harga berbasis *fixed price* untuk menghasilkan total tagihan secara otomatis?

1.3 Komponen Perancangan

Sistem *checkout* otomatis yang dirancang dalam penelitian ini terdiri atas tiga komponen utama yang saling terhubung dalam proses *checkout*, yaitu kamera, model YOLO11-seg, dan program kalkulasi harga.

1. Kamera

Kamera berfungsi sebagai komponen akuisisi citra pada proses *checkout*. Kamera digunakan untuk memperoleh citra piring yang telah berisi lauk pilihan pelanggan. Citra tersebut kemudian digunakan sebagai masukan bagi model YOLO11-seg untuk melakukan proses pengenalan lauk.

2. Model YOLO11-seg

YOLO11-seg merupakan komponen utama dalam pemrosesan *Computer Vision* pada sistem. Model ini digunakan untuk mendeteksi dan melakukan *instance segmentation* terhadap lauk yang terdapat pada citra piring. Dari hasil prediksi tersebut, sistem memperoleh kelas dan setiap instans lauk yang terdeteksi sehingga jumlah lauk dari masing-masing kelas dapat dihitung.

3. Program Kalkulasi Harga

Program kalkulasi harga berfungsi mengolah hasil pengenalan dan penghitungan instans dari YOLO11-seg menjadi total pembayaran. Program menggunakan harga tetap untuk setiap kelas lauk, kemudian menghitung total harga berdasarkan jenis dan jumlah instans lauk yang terdeteksi.

1.4 Spesifikasi Perancangan

Spesifikasi perancangan sistem *checkout* otomatis lauk Nasi Padang dalam penelitian ini terdiri atas tiga modul utama yang saling terhubung, yaitu modul akuisisi citra, modul pengenalan lauk menggunakan YOLO11-seg, dan modul kalkulasi harga.

1. Modul Akuisisi Citra

Modul akuisisi citra berfungsi memperoleh citra piring yang berisi lauk pilihan pelanggan menggunakan kamera. Citra yang diperoleh digunakan sebagai masukan bagi model YOLO11-seg. Sistem menggunakan citra digital dua dimensi dalam format RGB sebagai data masukan.

2. Modul Pengenalan Lauk dengan YOLO11-seg

Modul pengenalan lauk menggunakan YOLO11-seg untuk mendeteksi dan melakukan *instance segmentation* terhadap lauk yang terdapat pada citra. Model menghasilkan prediksi kelas serta *mask* untuk setiap instans objek yang terdeteksi.

Hasil prediksi tersebut digunakan untuk menentukan jumlah instans pada setiap kelas. Setiap instans yang terdeteksi dihitung secara individual sehingga beberapa objek dari kelas yang sama tetap dapat dibedakan dan dihitung sebagai objek yang terpisah.

Pengenalan dibatasi pada sembilan kelas, yaitu nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal.

3. Modul Kalkulasi Harga

Modul kalkulasi harga menggunakan jenis dan jumlah instans lauk yang telah dikenali untuk menentukan total pembayaran. Setiap kelas lauk memiliki harga tetap, kemudian total pembayaran dihitung berdasarkan jumlah instans dari masing-masing kelas. Penentuan harga tidak menggunakan berat, volume, luas *pixel mask*, maupun ukuran porsi.

1.5 Kegunaan Rancangan

Hasil perancangan sistem checkout otomatis ini diharapkan dapat memberikan kegunaan secara operasional maupun teknis dan akademis. Secara keseluruhan, rancangan ini menjadi *proof-of-concept* penerapan *self-service* dan otomatisasi proses *checkout* pada restoran Nasi Padang dengan memanfaatkan *Computer Vision*.

Secara operasional, sistem yang dirancang dapat digunakan sebagai alternatif mekanisme *checkout* bagi pelanggan *dine-in*. Sistem memanfaatkan YOLO11-seg untuk mengenali dan menghitung lauk yang terdapat pada piring, kemudian hasil tersebut digunakan untuk menentukan total pembayaran secara otomatis. Penerapan mekanisme ini diharapkan dapat mengurangi ketergantungan terhadap staf dalam proses pencatatan lauk pelanggan *dine-in* serta memberikan alternatif pelayanan yang lebih mandiri.

Secara teknis dan akademis, penelitian ini memberikan penerapan dan evaluasi YOLO11-seg pada *use-case* pengenalan dan penghitungan lauk Nasi Padang yang memiliki karakteristik objek dan kelas yang spesifik. Hasil evaluasi dapat memberikan gambaran mengenai kemampuan model dalam mendeteksi, melakukan *instance segmentation*, dan menghitung setiap instans lauk. Dengan demikian, penelitian ini dapat menjadi referensi awal untuk penerapan *Computer Vision* berbasis *instance segmentation* pada sistem *checkout* makanan dengan jenis dan jumlah objek sebagai dasar penentuan harga.

1.6 Rancangan yang Sudah Dibuat

Beberapa penelitian sebelumnya telah mengembangkan sistem dan metode yang berkaitan dengan pengenalan makanan, *instance segmentation*, penghitungan instans, dan sistem *checkout* otomatis. Beberapa rancangan yang relevan dengan penelitian ini adalah sebagai berikut:

1. Perancangan yang berjudul “Grab, Pay and Eat: Semantic Food Detection for Smart Restaurants” oleh Aguilar et al. mengembangkan metode *Semantic Food Detection* untuk menganalisis makanan pada nampan di lingkungan restoran. Metode tersebut menggabungkan proses lokalisasi, pengenalan, deteksi, dan segmentasi makanan untuk mendukung penerapan *automatic billing* pada restoran *self-service*. Penelitian tersebut memperoleh nilai F-measure sekitar 90% pada dataset UNIMIB2016 [8].
2. Perancangan yang berjudul “A Framework of Visual Checkout System Using Convolutional Neural Networks for Bento Buffet” oleh Wu et al. mengembangkan sistem *visual checkout* untuk restoran Bento Buffet menggunakan kamera Kinect dan CNN. Sistem melakukan pengenalan makanan serta menggunakan informasi kedalaman untuk memperkirakan volume makanan dan harga. Pendekatan pengenalan dua tahap yang digunakan menghasilkan akurasi sebesar 96,3% pada dataset pengujian [9].
3. Perancangan yang berjudul “A Real-Time Chinese Food Auto Billing System Based on Instance Segmentation” oleh Guo et al. mengembangkan sistem perhitungan harga makanan Tiongkok secara otomatis menggunakan segmentasi. Sistem mengenali jenis piring berdasarkan bentuk dan ukuran, di mana setiap jenis piring merepresentasikan harga tertentu. Penelitian tersebut juga mengembangkan FoodSyn untuk menghasilkan data sintesis dan memperoleh nilai mIoU lebih dari 95% pada pengujian yang dilakukan [3].

4. Perancangan yang berjudul “SibNet: Food Instance Counting and Segmentation” oleh Nguyen et al. mengembangkan jaringan multi-task untuk melakukan penghitungan dan segmentasi instans makanan secara bersamaan. SibNet dirancang untuk menangani karakteristik makanan dengan bentuk yang tidak beraturan serta kondisi objek yang saling menutupi melalui penggunaan *instance seed* dan *sibling relation network* [4].
5. Perancangan yang berjudul “FoodMask: Real-time Food Instance Counting, Segmentation and Recognition” oleh Nguyen et al. mengembangkan jaringan multi-task untuk melakukan penghitungan, segmentasi, dan pengenalan instans makanan secara bersamaan. FoodMask menghasilkan informasi kategori makanan dan instans pada tingkat piksel serta dirancang untuk melakukan pemrosesan secara *real-time* pada citra yang dapat berisi beberapa jenis makanan [5].
6. Perancangan yang berjudul “Indonesian Street Food Calorie Estimation Using Mask R-CNN and Multiple Linear Regression” oleh Aditama dan Munir menerapkan Mask R-CNN untuk melakukan *amodal instance segmentation* terhadap enam kelas jajanan Indonesia. Penelitian tersebut secara khusus mengevaluasi kondisi oklusi dan non-oklusi, dengan F1-score sebesar 0,821 pada kondisi oklusi dan 0,994 pada kondisi non-oklusi [10].

BAB II

LANDASAN TEORETIK

2.1 Sistem yang Dirancang

Sistem yang dirancang dalam penelitian ini merupakan sistem *checkout* otomatis untuk mengenali lauk Nasi Padang berdasarkan citra. Sistem ditujukan sebagai *proof-of-concept* penerapan mekanisme *self-service* bagi pelanggan *dine-in*, sehingga jenis dan jumlah lauk yang terdapat pada piring dapat dikenali secara otomatis dan digunakan sebagai dasar untuk menentukan total pembayaran.


Penerapan *Computer Vision* pada proses *checkout* makanan telah dikembangkan pada beberapa penelitian sebelumnya, antara lain melalui analisis makanan pada nampan untuk *automatic billing*, sistem *visual checkout*, dan sistem perhitungan harga makanan berbasis segmentasi [8, 9, 3]. Pada penelitian ini, pengenalan lauk dilakukan menggunakan YOLO11-seg yang menghasilkan prediksi pada tingkat instans sehingga objek dari kelas yang sama tetap dapat dibedakan dan dihitung secara individual.

Pengembangan model dilakukan menggunakan dataset citra Nasi Padang yang telah dianotasi. Dataset digunakan dalam proses pelatihan, validasi, dan pengujian model. Data pelatihan digunakan untuk memperbarui bobot YOLO11-seg, data validasi digunakan untuk memantau performa model selama pelatihan, sedangkan data pengujian digunakan untuk menilai model akhir pada citra yang tidak digunakan dalam proses pembelajaran.

Pada tahap penggunaan, kamera memperoleh citra piring yang berisi lauk pilihan pelanggan. Citra tersebut diproses oleh YOLO11-seg untuk menghasilkan kelas dan *segmentation mask* untuk setiap instans yang dikenali. Setiap instans kemudian dihitung berdasarkan kelasnya. Informasi jenis dan jumlah lauk selanjutnya diteruskan ke program kalkulasi harga yang menggunakan harga tetap

pada setiap kelas untuk memperoleh total pembayaran. Penentuan harga tidak menggunakan berat, volume, luas *mask*, maupun ukuran porsi.

Objek yang dapat dikenali pada sistem dibatasi pada sembilan kelas, yaitu nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal. Alur keseluruhan sistem, mulai dari pengembangan model hingga proses *checkout*, ditunjukkan pada Gambar 2.1.



Gambar 2.1: Diagram alur pelatihan dan inferensi sistem *checkout* otomatis

Konsep teoritik yang mendukung proses pengenalan, penghitungan instans, kalkulasi harga, dan evaluasi sistem dijelaskan pada bagian selanjutnya.

2.2 Landasan Teori

Landasan teori pada bagian ini membahas konsep yang digunakan untuk memahami rancangan sistem *checkout* otomatis Nasi Padang. Pembahasan diawali dengan Nasi Padang untuk menjelaskan karakteristik makanan dan bentuk penyajian yang menjadi ruang lingkup penelitian. Selanjutnya, pembahasan mencakup *Computer Vision* dan citra digital, *instance segmentation*, YOLO11-seg, penghitungan instans dan perhitungan total harga, serta evaluasi kinerja model dan sistem. Detail mengenai dataset, konfigurasi pelatihan, perangkat, dan prosedur pengujian dibahas pada Bab III.

2.2.1 Nasi Padang

Nasi Padang merupakan salah satu bentuk penyajian masakan Minangkabau yang berasal dari Sumatera Barat. Istilah Nasi Padang tidak hanya merujuk pada nasi sebagai makanan utama, tetapi pada penyajian nasi putih bersama beragam masakan pendamping. Masakan tersebut dapat berupa olahan daging, ayam, ikan, sayuran, gulai, dan sambal. Beberapa lauk yang umum dikenal dalam penyajian Nasi Padang antara lain rendang, ayam berbumbu, dan perkedel [11]. Keragaman tersebut membuat pelanggan dapat memilih jenis dan jumlah lauk sesuai dengan keinginan.

Seporsi Nasi Padang dapat memadukan nasi dengan lauk, kuah gulai, sambal, dan sayuran. Pilihan lauknya dapat berasal dari olahan daging maupun ikan, sedangkan sayur yang disajikan antara lain sayur nangka dan daun singkong [12]. Dengan demikian, satu piring Nasi Padang dapat berisi beberapa jenis makanan dengan bentuk, warna, dan tekstur visual yang berbeda.

Pada pelayanan makan di tempat atau *dine-in*, terdapat dua metode penyajian yang dikenal sebagai *hidang* dan *pesan*. Pada metode *hidang*, sejumlah piring kecil yang berisi lauk berbeda dibawa oleh pelayan dan diletakkan di meja pelanggan.

Pelanggan kemudian membayar lauk yang dikonsumsi. Sementara itu, pada metode *pesan*, pelanggan memilih lauk dari makanan yang ditampilkan pada etalase, kemudian nasi dan lauk yang dipilih disajikan kepada pelanggan [11].



Gambar 2.2: Contoh penyajian Nasi Padang untuk pelanggan *dine-in*

Sumber: Dokumentasi Pribadi

Selain disajikan untuk makan di tempat, Nasi Padang juga dapat disiapkan untuk dibawa pulang atau *take-away*. Pada bentuk penyajian ini, nasi, lauk, sayur, sambal, dan kuah yang dipilih ditempatkan dalam satu bungkus. Penggunaan daun pisang sebagai bagian dari pembungkus juga menjadi salah satu bentuk penyajian Nasi Padang untuk dibawa pulang. Pada sejumlah rumah makan, porsi nasi dalam penyajian bungkus dapat lebih banyak dibandingkan dengan penyajian makan di tempat. Salah satu alasan yang dikemukakan adalah bahwa nasi bungkus pada awalnya dapat dikonsumsi bersama oleh lebih dari satu orang [12].



Gambar 2.3: Contoh penyajian Nasi Padang untuk *take-away*

Sumber: Fitria, DetikFood (2020), diakses 29 Agustus 2026

Perbedaan cara penyajian tersebut menghasilkan kondisi visual yang berbeda. Pada penyajian *dine-in*, nasi dan lauk berada dalam kondisi terbuka pada piring sehingga dapat diamati secara langsung dari arah atas. Sebaliknya, pada penyajian *take-away*, seluruh makanan telah digabungkan dan ditempatkan di dalam bungkus. Oleh karena itu, sistem yang dirancang dalam penelitian ini difokuskan pada penyajian *dine-in*. Pembahasan mengenai penyajian *take-away* digunakan untuk memberikan konteks mengenai perbedaan bentuk penyajian Nasi Padang, tetapi tidak termasuk dalam ruang lingkup pengenalan lauk oleh sistem.

2.2.2 **Computer Vision dan Citra Digital**


Computer Vision digunakan untuk memperoleh informasi dari citra melalui proses komputasi. Pada analisis makanan, informasi visual dapat dimanfaatkan untuk melakukan pengenalan, deteksi, dan segmentasi objek sehingga jenis serta lokasi makanan pada citra dapat ditentukan [8].

Citra digital berwarna tersusun atas nilai piksel pada beberapa kanal warna. Informasi tersebut menjadi masukan bagi model untuk membentuk representasi fitur yang berkaitan dengan karakteristik visual objek, seperti bentuk, warna, tekstur, dan susunan objek pada citra. Pada sistem yang dirancang, citra piring digunakan sebagai masukan bagi YOLO11-seg untuk mengenali lauk pada tingkat instans.

Karena pengambilan citra pada sistem dilakukan dari posisi tetap di atas piring, area objek dapat diamati dengan perspektif yang relatif konsisten. Pendekatan pengambilan citra dari arah atas juga digunakan pada sistem *visual checkout* makanan untuk memperoleh tampilan objek pada area pengamatan secara konsisten [9].

2.2.3 Instance Segmentation

Instance segmentation merupakan tugas *Computer Vision* yang menghasilkan kelas dan *mask* pada tingkat piksel untuk setiap instans objek. Berbeda dengan deteksi objek yang menunjukkan lokasi objek menggunakan *bounding box*, *instance segmentation* juga menunjukkan wilayah piksel yang membentuk objek tersebut. Sementara itu, segmentasi semantik memberikan label kelas pada setiap piksel tanpa membedakan objek berbeda yang termasuk dalam kelas yang sama. Dengan demikian, *instance segmentation* menggabungkan informasi kelas, lokasi, dan wilayah piksel dengan tetap mempertahankan identitas setiap objek sebagai instans yang terpisah [2, 13].



Gambar 2.4: Perbandingan klasifikasi citra, lokalisasi objek, segmentasi semantik, dan *instance segmentation*

Sumber: [13]

Perbedaan antara segmentasi semantik dan *instance segmentation* menjadi penting ketika terdapat lebih dari satu objek dari kelas yang sama. Sebagai contoh, apabila terdapat dua perkedel pada satu piring, segmentasi semantik memberikan label kelas perkedel pada piksel kedua objek tersebut tanpa mempertahankan identitas masing-masing objek. Sebaliknya, *instance segmentation* menghasilkan *mask* yang terpisah untuk perkedel pertama dan perkedel kedua. Pemisahan tersebut memungkinkan keduanya dihitung sebagai dua instans meskipun memiliki kelas yang sama.

Pemisahan pada tingkat instans sesuai dengan kebutuhan sistem karena satu piring dapat mengandung lebih dari satu lauk dari kelas yang sama. Pendekatan segmentasi dan penghitungan pada tingkat instans juga telah digunakan untuk mengenali dan menghitung objek makanan [4, 5].

Pada sistem yang dirancang, keluaran *instance segmentation* digunakan untuk memperoleh kelas dan identitas setiap instans lauk. Jumlah lauk ditentukan berdasarkan banyaknya instans yang terdapat pada hasil prediksi akhir. Luas *segmentation mask* tidak digunakan untuk menentukan jumlah maupun harga lauk.


2.2.4 YOLO11-seg

YOLO11-seg merupakan varian YOLO11 yang mendukung tugas *instance segmentation*. Model ini digunakan untuk menghasilkan prediksi lokasi objek, kelas, dan *segmentation mask* dalam satu model sehingga proses klasifikasi lauk dan segmentasi tidak memerlukan dua model yang terpisah [6, 7].

YOLO11-seg dipilih dibandingkan versi yang lebih baru seperti YOLO12 karena dokumentasi dan pengujiannya untuk tugas *instance segmentation* lebih lengkap, termasuk ketersediaan bobot pralatih segmentasi dan penerapan pada penelitian terdahulu [7].

a. Arsitektur YOLO11-seg

Diagram arsitektur YOLO11-seg memperlihatkan tiga bagian utama, yaitu *backbone*, *neck*, dan *segmentation head*. Aliran pemrosesan dimulai dari citra masukan pada sisi kiri diagram, dilanjutkan dengan ekstraksi dan penggabungan fitur, kemudian berakhir pada tiga blok *Segment*. Secara umum, *backbone* bertugas mengekstraksi fitur dari citra, *neck* menggabungkan fitur pada beberapa skala, sedangkan *segmentation head* menghasilkan informasi kelas, lokasi objek, dan segmentasi untuk setiap instans [6, 7].



Gambar 2.5: Arsitektur YOLO11-seg

Sumber: [7]

Backbone. Pada bagian atas diagram, citra masukan diproses secara bertahap melalui rangkaian modul CBS dan C3k2. CBS terdiri atas operasi konvolusi, *batch normalization*, dan fungsi aktivasi SiLU. Setelah itu, modul C3k2 melanjutkan proses ekstraksi fitur dari keluaran CBS. Rangkaian CBS dan C3k2 digunakan beberapa kali sehingga ukuran spasial peta fitur semakin kecil pada tahapan yang lebih dalam, sementara informasi yang direpresentasikan menjadi semakin kuat. Pada bagian akhir *backbone*, SPPF (*Spatial Pyramid Pooling-Fast*) mengumpulkan

informasi konteks melalui operasi *pooling* pada beberapa cakupan, kemudian C2PSA menggunakan mekanisme perhatian untuk menekankan informasi fitur yang relevan [6, 7].

Neck. Bagian tengah diagram memperlihatkan bahwa fitur dari *backbone* tidak langsung diteruskan ke bagian keluaran. Fitur terdalam terlebih dahulu diperbesar resolusinya melalui operasi *upsample*, kemudian digabungkan dengan fitur dari tahapan sebelumnya melalui operasi *concat*. Jalur ini membawa informasi semantik dari fitur yang lebih dalam menuju fitur beresolusi lebih tinggi. Setelah itu, terdapat jalur kembali menuju resolusi yang lebih rendah melalui modul CBS dan operasi *concat*. Susunan tersebut memungkinkan detail spasial dari fitur beresolusi tinggi dipadukan dengan informasi semantik dari fitur yang lebih dalam [6, 7].

Dalam satu tingkat resolusi, beberapa lapisan dapat menghasilkan peta fitur dengan ukuran spasial yang sama. Pada konsep *Feature Pyramid Network*, keluaran dari lapisan terakhir pada setiap tingkat dipilih karena telah melalui pemrosesan yang lebih dalam sehingga diharapkan memiliki representasi fitur yang lebih kuat [14]. Prinsip tersebut terlihat pada diagram YOLO11-seg melalui penggunaan keluaran setelah modul C3k2 pada tingkat P3, P4, dan P5 dalam proses penggabungan fitur. Ketiga tingkat tersebut menghasilkan peta fitur dengan resolusi berbeda dan selanjutnya diteruskan ke bagian *segmentation head*.

Segmentation head. Pada bagian *head* yang terletak di bawah *neck*, fitur P3, P4, dan P5 masing-masing diteruskan ke blok *Segment*. Penggunaan tiga tingkat fitur memungkinkan model melakukan prediksi terhadap objek pada skala yang berbeda. Bagian ini menghasilkan prediksi kelas objek dan posisi *bounding box*, serta informasi yang diperlukan untuk membentuk *mask* setiap instans. Oleh karena itu, klasifikasi lauk, penentuan lokasi objek, dan segmentasi dihasilkan dalam satu arsitektur YOLO11-seg, bukan melalui model yang terpisah [7].

Diagram arsitektur utama hanya menampilkan bagian ini sebagai blok *Segment* dan tidak memperlihatkan proses pembentukan *mask* secara terperinci. Di dalam *segmentation head*, fitur yang diterima digunakan untuk menghasilkan prediksi kelas, posisi *bounding box*, dan koefisien *mask*. Selain itu, dibentuk sekumpulan *prototype mask* yang digunakan bersama oleh seluruh kandidat objek. Koefisien *mask* dari setiap objek kemudian dikombinasikan dengan *prototype mask* untuk menghasilkan *mask* khusus bagi objek tersebut [15, 7].

Karena setiap kandidat objek memiliki koefisien *mask* tersendiri, dua objek dengan kelas yang sama tetap dapat menghasilkan *mask* yang berbeda dan dihitung sebagai dua instans. Dalam penelitian ini, kelas hasil prediksi digunakan untuk menentukan jenis lauk, sedangkan jumlah instans pada setiap kelas digunakan dalam proses kalkulasi harga.

b. Pelatihan YOLO11-seg

Pelatihan model dapat dimulai dari bobot pralatih agar fitur visual yang telah dipelajari sebelumnya dapat digunakan sebagai titik awal dan kemudian disesuaikan dengan kelas pada dataset penelitian. Pada penelitian ini, bobot YOLO11-seg disesuaikan untuk mengenali sembilan kelas, yaitu nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal.

Pada proses pelatihan, citra dan *ground truth* diberikan kepada model untuk menghasilkan prediksi lokasi objek, kelas, dan segmentasi. Prediksi tersebut dibandingkan dengan *ground truth* untuk memperoleh nilai *loss*. Nilai *loss* kemudian digunakan dalam proses *backpropagation* untuk memperbarui bobot model secara berulang. Data validasi digunakan untuk memantau performa model selama pelatihan, sedangkan data pengujian digunakan setelah model akhir diperoleh.

Nilai parameter pelatihan, seperti varian YOLO11-seg, ukuran citra masukan, jumlah *epoch*, *batch size*, konfigurasi augmentasi, dan parameter lain yang digunakan pada implementasi dijelaskan pada Bab III.

2.2.5 Penghitungan Instans dan Perhitungan Total Harga

Penghitungan objek makanan dilakukan berdasarkan hasil prediksi akhir YOLO11-seg. Setiap prediksi akhir merepresentasikan satu instans objek, sedangkan label kelas menentukan kelompok tempat instans tersebut dihitung. Dengan demikian, penghitungan dilakukan berdasarkan jumlah instans yang dikenali, bukan berdasarkan jumlah piksel atau luas *segmentation mask*.

Program memeriksa setiap hasil prediksi dan menambahkan jumlah pada kelas yang sesuai. Apabila hasil inferensi menghasilkan dua instans rendang dan satu instans perkedel, jumlah rendang yang tercatat adalah dua dan jumlah perkedel adalah satu. Prinsip penghitungan pada tingkat instans juga digunakan dalam penelitian penghitungan makanan seperti SibNet dan FoodMask [4, 5].

Jumlah instans pada setiap kelas selanjutnya digunakan untuk menghitung total harga. Setiap kelas memiliki harga satuan tetap yang disimpan sebagai data pada program. YOLO11-seg tidak menentukan harga makanan; model hanya menghasilkan kelas dan instans objek, sedangkan proses penghitungan harga dilakukan oleh program. Pemanfaatan hasil pengenalan citra sebagai dasar perhitungan harga juga diterapkan pada penelitian mengenai *automatic billing* dan *visual checkout* makanan [9, 3].

Subtotal suatu kelas diperoleh dengan mengalikan jumlah instans pada kelas tersebut dengan harga satuannya. Total harga kemudian diperoleh dengan menjumlahkan subtotal dari seluruh kelas yang dikenali. Perhitungan tersebut dinyatakan pada Persamaan 2.1.

$$T = \sum_{i=1}^C n_i p_i \quad (2.1)$$

dengan:

- T adalah total harga yang harus dibayarkan;
- C adalah jumlah kelas makanan;
- n_i adalah jumlah instans yang dikenali pada kelas ke- i ; dan
- p_i adalah harga satuan makanan pada kelas ke- i .

Sebagai contoh, apabila sistem mengenali dua instans rendang dan satu instans perkedel, subtotal rendang diperoleh dengan mengalikan dua dengan harga satuan rendang. Subtotal perkedel diperoleh dengan mengalikan satu dengan harga satuan perkedel. Total pembayaran merupakan penjumlahan kedua subtotal tersebut beserta subtotal kelas lain yang dikenali.

Penentuan harga tidak menggunakan berat, volume, luas *mask*, maupun ukuran porsi. Harga satuan disimpan secara terpisah dari model sehingga perubahan harga tidak memerlukan pelatihan ulang YOLO11-seg selama identitas kelas pada program tetap sesuai dengan keluaran model.

2.2.6 Evaluasi Kinerja Model dan Sistem

Evaluasi dilakukan untuk menjawab empat pertanyaan. Pertama, apakah model dapat menemukan dan mengenali kelas lauk dengan benar. Kedua, apakah bentuk *mask* yang dihasilkan sesuai dengan bentuk lauk sebenarnya. Ketiga, apakah jumlah lauk pada setiap kelas telah dihitung dengan benar. Keempat, berapa lama waktu yang diperlukan model untuk memproses satu citra.

Metrik evaluasi pada bagian ini berbeda dari *loss*. Nilai *loss* digunakan selama pelatihan untuk membantu model memperbaiki bobotnya. Setelah pelatihan

selesai, metrik evaluasi digunakan untuk mengukur kemampuan model pada data pengujian.

a. Evaluasi Deteksi dan Pengenalan Kelas

Bagian ini menilai apakah model berhasil menemukan lauk, memberikan kelas yang benar, dan menentukan lokasi lauk menggunakan *bounding box*. Sebagai contoh, apabila terdapat rendang pada citra, model diharapkan dapat menemukan objek tersebut, memberikan kelas rendang, dan menempatkan *bounding box* pada lokasi yang sesuai.

Kesesuaian lokasi diukur menggunakan *Intersection over Union* (IoU). IoU membandingkan luas bagian yang saling bertumpang tindih dengan luas gabungan antara wilayah prediksi dan *ground truth*. Jika A merupakan wilayah prediksi dan B merupakan wilayah *ground truth*, IoU dinyatakan pada Persamaan 2.2 [7].

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (2.2)$$

Nilai IoU mendekati satu menunjukkan bahwa kedua wilayah semakin sesuai. Pada evaluasi deteksi, wilayah yang dibandingkan adalah *bounding box*. Prediksi yang kelas dan *bounding box*-nya sesuai dengan *ground truth* dinyatakan sebagai *true positive* (TP). Prediksi yang tidak sesuai dinyatakan sebagai *false positive* (FP), sedangkan objek yang terdapat pada *ground truth* tetapi tidak ditemukan oleh model dinyatakan sebagai *false negative* (FN).

Precision menjawab pertanyaan: dari seluruh objek yang ditemukan oleh model, berapa banyak yang benar. Nilainya dinyatakan pada Persamaan 2.3.

$$Precision = \frac{TP}{TP + FP} \times 100\% \quad (2.3)$$

Recall menjawab pertanyaan: dari seluruh objek yang sebenarnya terdapat pada citra, berapa banyak yang berhasil ditemukan oleh model. Nilainya dinyatakan pada Persamaan 2.4.

$$Recall = \frac{TP}{TP + FN} \times 100\% \quad (2.4)$$

F1-score menggabungkan *precision* dan *recall* menjadi satu nilai. Metrik ini digunakan untuk melihat keseimbangan antara ketepatan prediksi dan kemampuan model menemukan objek. *F1-score* dinyatakan pada Persamaan 2.5 [16].

$$F1 = 2 \times Precision \times \frac{Recall}{Precision + Recall} \quad (2.5)$$

Kinerja deteksi secara keseluruhan dirangkum menggunakan *box mean Average Precision (box mAP)*. *Box mAP50* menggunakan ambang IoU sebesar 0,50. *Box mAP50–95* menggunakan beberapa ambang IoU dari 0,50 hingga 0,95 sehingga penilaiannya lebih ketat. Nilai yang lebih tinggi menunjukkan performa deteksi dan pengenalan kelas yang lebih baik [7, 17].

b. Evaluasi Segmentasi

Bagian ini menilai apakah *mask* hasil prediksi mengikuti bentuk lauk dengan benar. Sebagai contoh, *mask* rendang seharusnya menutupi piksel yang termasuk rendang dan tidak menutupi bagian piring atau lauk lainnya.

IoU pada Persamaan 2.2 juga digunakan dalam evaluasi segmentasi. Perbedaannya, wilayah *A* dan *B* yang dibandingkan pada bagian ini adalah *mask* prediksi dan *mask ground truth*, bukan *bounding box*. Semakin besar tumpang tindih kedua *mask*, semakin tinggi nilai IoU.

Kinerja segmentasi dirangkum menggunakan *mask precision*, *mask recall*, *mask mAP50*, dan *mask mAP50–95*. Pengertian *precision* dan *recall* tetap sama, tetapi kecocokan prediksi ditentukan berdasarkan tumpang tindih *mask*. *Mask*

mAP50 menggunakan ambang mask IoU sebesar 0,50, sedangkan *mask mAP50–95* menggunakan beberapa ambang dari 0,50 hingga 0,95 [7, 17]. Dalam penelitian ini, IoU dijelaskan sebagai dasar pencocokan *mask*, sedangkan hasil segmentasi dilaporkan menggunakan metrik *mask mAP*.

c. Evaluasi Penghitungan Instans

Bagian ini menilai apakah sistem menghasilkan jumlah lauk yang benar pada setiap kelas. Penghitungan dilakukan berdasarkan banyaknya instans hasil prediksi akhir, bukan berdasarkan luas *mask*, berat, volume, atau ukuran porsi.

Sebagai contoh, apabila pada suatu citra terdapat dua rendang tetapi sistem hanya menghitung satu rendang, selisih jumlahnya adalah satu. Jika jumlah pada *ground truth* dan hasil prediksi sama-sama dua, selisih jumlahnya adalah nol.

Mean Absolute Error (MAE) digunakan untuk menghitung rata-rata selisih jumlah tersebut pada seluruh citra pengujian [4]. Untuk kelas ke- i pada N citra pengujian, MAE dinyatakan pada Persamaan 2.6.

$$MAE_i = \frac{1}{N} \sum_{j=1}^N |\hat{n}_{ji} - n_{ji}| \quad (2.6)$$

Pada persamaan tersebut, i menunjukkan kelas lauk yang sedang dinilai dan j menunjukkan citra pengujian. Nilai $\hat{n}_{ji}$ adalah jumlah hasil prediksi, sedangkan n_{ji} adalah jumlah berdasarkan *ground truth*. Nilai MAE yang semakin kecil menunjukkan hasil penghitungan yang semakin baik. MAE bernilai nol berarti tidak terdapat perbedaan antara jumlah prediksi dan jumlah sebenarnya pada data yang dievaluasi.

d. Evaluasi Kecepatan Inferensi

Bagian ini menilai waktu yang diperlukan model untuk memproses satu citra. Kecepatan dilaporkan sebagai waktu inferensi rata-rata per citra. Waktu yang lebih

kecil menunjukkan bahwa model dapat menghasilkan prediksi dengan lebih cepat [17]. Perangkat, data pengujian, dan prosedur pengukurannya dijelaskan pada Bab III.

BAB III

RANCANGAN DAN PEMBUATAN

3.1 Rancangan Sistem

Sistem yang dirancang merupakan sistem *checkout* otomatis untuk mengenali dan menghitung lauk Nasi Padang menggunakan YOLO11-seg. Sistem ditujukan sebagai *proof-of-concept* mekanisme *self-service* bagi pelanggan *dine-in*. Pada proses penggunaan, piring yang berisi lauk ditempatkan pada area pengambilan citra, kemudian kamera pada posisi tetap memperoleh citra dari arah atas. Citra tersebut diproses oleh YOLO11-seg untuk menghasilkan prediksi pada tingkat instans yang selanjutnya digunakan untuk menghitung jumlah lauk dan menentukan total harga berdasarkan tabel harga tetap.

Sebelum digunakan pada proses *checkout*, model terlebih dahulu disiapkan melalui pengumpulan dan anotasi data, pembagian dataset, augmentasi data pelatihan, serta proses pelatihan dan validasi. Model yang telah dipilih kemudian dievaluasi menggunakan data pengujian dan digunakan pada alur *checkout*.

Rancangan sistem dibahas melalui tiga bagian, yaitu perencanaan sistem, analisis sistem, dan perancangan alur sistem. Perencanaan sistem membahas persiapan dataset, analisis sistem menjabarkan kebutuhan yang diperlukan dalam pengembangan, sedangkan perancangan sistem menjelaskan rancangan pelatihan model dan proses *checkout*.

3.1.1 Perencanaan Sistem

Perencanaan sistem diawali dengan menyiapkan dataset yang sesuai dengan sembilan kelas penelitian, yaitu nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal. Persiapan dataset

mencakup pengumpulan dan seleksi citra, anotasi setiap instans objek, pembagian dataset menjadi data pelatihan, validasi, dan pengujian, serta augmentasi yang diterapkan pada data pelatihan.

Tahapan persiapan dataset tersebut dijelaskan pada subbagian berikut.

3.1.1.1 Pengumpulan Data

Pengumpulan data dilakukan untuk memperoleh citra yang digunakan dalam proses pelatihan, validasi, dan pengujian YOLO11-seg. Proses ini terdiri atas dua tahap, yaitu menyiapkan citra acuan secara manual dan mengumpulkan citra tambahan dari internet menggunakan program *crawler*.

Pada tahap pertama, sebanyak 21 citra Nasi Padang dikumpulkan dan dipilih secara manual sebagai citra acuan. Citra-citra tersebut memuat nasi dan berbagai lauk yang termasuk dalam kelas penelitian. Citra acuan digunakan sebagai masukan pencarian agar citra tambahan yang ditemukan memiliki kemiripan visual dengan makanan yang akan dikenali oleh sistem.



Gambar 3.1: Contoh citra acuan yang digunakan dalam proses pengumpulan data

Sumber: Dokumentasi pribadi

Pada tahap kedua, citra tambahan dikumpulkan menggunakan program *crawler* berbasis Python yang dijalankan melalui Google Colab. Setiap citra acuan digunakan untuk melakukan pencarian visual melalui Google Lens dengan bantuan SerpApi. Program kemudian memeriksa hasil pencarian dan mengunduh citra yang memenuhi ketentuan. Batas maksimum pengumpulan ditetapkan sebanyak 50 hasil untuk setiap citra acuan. Jumlah tersebut merupakan batas pengumpulan, bukan jumlah yang harus selalu diperoleh, karena banyaknya hasil yang sesuai berbeda untuk setiap citra acuan.

Penyaringan dilakukan secara otomatis selama proses pengumpulan. Domain GoFood dan Gojek, yang mencakup `gofood.co.id`, `gojek.com`, `go-jek.com`, dan `gojekapi.com`, dimasukkan ke dalam daftar blokir karena citra dari domain tersebut umumnya memiliki tanda air berukuran besar yang dapat mengganggu informasi visual makanan. Program juga menolak citra dengan lebar atau tinggi kurang dari 256 piksel.

Selain penyaringan domain dan ukuran, program melakukan pemeriksaan duplikasi. Citra yang sama diperiksa menggunakan nilai *hash* dari data piksel, sedangkan citra yang memiliki tampilan sangat mirip diperiksa menggunakan *perceptual hash*. Dengan pemeriksaan tersebut, citra yang sama maupun citra yang hanya berbeda karena perubahan ukuran atau kompresi tidak disimpan kembali. Alamat citra dan halaman sumber dari setiap hasil yang berhasil disimpan dicatat dalam berkas `manifest.csv`.

```

Running Lens search #2...
Candidates found: 59
SKIPPED: ValueError Image too small: 225x225
SKIPPED: ValueError Image too small: 225x225
SKIPPED: ValueError Image too small: 168x299
BLOCKED DOMAIN: gofood.co.id, i.gojekapi.com
SAVED 13/50 -> 20260812_164252_Secab756_013.jpg
SKIPPED: ValueError Image too small: 201x251
BLOCKED DOMAIN: gofood.co.id, i.gojekapi.com
SKIPPED: UnicodeEncodeError 'latin-1' codec can't encode characters in position 41-51: ordinal not in range(256)
SKIPPED: ValueError Image too small: 194x259
SAVED 14/50 -> 20260812_164252_Secab756_014.jpg
SKIPPED: ValueError Image too small: 220x220
BLOCKED DOMAIN: gofood.co.id, i.gojekapi.com
BLOCKED DOMAIN: gofood.co.id, i.gojekapi.com
BLOCKED DOMAIN: gofood.co.id, i.gojekapi.com
BLOCKED DOMAIN: gofood.co.id, i.gojekapi.com
SKIPPED: ValueError Image too small: 168x300
SKIPPED: ValueError Image too small: 201x251
SKIPPED: ValueError Image too small: 238x212
SKIPPED: ValueError Image too small: 259x194
SKIPPED: ValueError Image too small: 194x259

```

Gambar 3.2: Contoh proses penyaringan citra oleh program *crawler*

Sumber: Dokumentasi pribadi

Proses *crawling* menggunakan 21 citra acuan menghasilkan 392 citra kandidat sebelum pembersihan manual. Jumlah tersebut merupakan keluaran awal program dan bukan jumlah akhir citra yang digunakan sebagai data penelitian. Hasil ini lebih rendah daripada batas maksimum yang ditetapkan karena tidak setiap citra acuan menghasilkan 50 citra yang unik, dapat diunduh, dan memenuhi ketentuan penyaringan.

Reference	Count
20260812_164252.jpg	50
20260812_164327.jpg	11
20260812_164354.jpg	26
20260815_111800.jpg	34
20260815_111836.jpg	30
20260817_131708.jpg	36
20260817_131721.jpg	28
20260817_131748.jpg	14
20260817_131813.jpg	12
20260818_162054.jpg	15
20260818_162127.jpg	21
20260818_162203.jpg	11
padang_0043.jpg	11
padang_0044.jpg	19
padang_0047.jpg	15
padang_0051.jpg	6
padang_0054.jpg	14
padang_0055.jpg	11
padang_0059.jpg	16
padang_0065.jpg	6
padang_0072.jpg	6
TOTAL	392
Target: 1050	

Gambar 3.3: Ringkasan hasil awal program *crawler* sebelum pembersihan manual

Sumber: Dokumentasi pribadi

Seluruh citra kandidat selanjutnya dibersihkan secara manual dalam dua tahap. Pada pembersihan pertama, citra yang tidak relevan, menampilkan objek makanan dengan tidak jelas, memiliki kualitas visual yang tidak memadai, atau menampilkan makanan dalam keadaan terbungkus untuk *take-away* dihapus sehingga tersisa lebih dari 300 citra. Pembatasan terhadap penyajian *dine-in* dilakukan karena sistem dirancang untuk mengenali nasi dan lauk yang disajikan secara terbuka dan diamati menggunakan kamera dari arah atas.

Pada seleksi manual kedua, citra yang tersisa diperiksa kembali sebelum dianotasi. Citra dihapus apabila tidak menggambarkan kondisi penggunaan sistem yang sebenarnya, yaitu piring yang diamati menggunakan kamera dari arah atas. Contohnya adalah citra yang diambil dari arah samping, citra dengan tanda air berukuran besar yang menutupi makanan, serta citra lain yang kurang sesuai dengan kondisi pengambilan citra pada area *checkout*. Setelah seleksi kedua, sebanyak 133 citra dipertahankan sebagai data penelitian.

Dengan demikian, alur pengumpulan data terdiri atas 21 citra acuan, 392 citra kandidat hasil *crawling*, lebih dari 300 citra setelah pembersihan pertama, dan 133 citra akhir setelah seleksi manual kedua. Jumlah akhir tersebut merupakan citra yang digunakan pada tahap anotasi dan pembagian dataset.

Dataset difokuskan pada sembilan kelas, yaitu nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal. Satu citra dapat memuat beberapa kelas sekaligus maupun lebih dari satu objek dari kelas yang sama. Citra yang telah lolos pemeriksaan selanjutnya digunakan pada tahap anotasi data untuk memberikan label kelas dan area segmentasi pada setiap objek.

3.1.1.2 Anotasi Data

Citra yang telah lolos tahap seleksi dianotasi untuk menghasilkan *ground truth* yang digunakan dalam pelatihan, validasi, dan pengujian YOLO11-seg. Proses

anotasi dilakukan menggunakan CVAT terhadap setiap instans objek makanan yang termasuk dalam kelas penelitian.

Kelas anotasi terdiri atas nasi, rendang, ayam goreng, perkedel, sayur nangka, daun singkong, telur dadar, telur kari, dan sambal. Objek makanan di luar sembilan kelas tersebut tidak diberikan anotasi dan diperlakukan sebagai bagian dari latar belakang.

Setiap objek dianotasi menggunakan poligon yang mengikuti batas objek yang terlihat pada citra. Poligon tersebut kemudian diberikan label sesuai dengan kelas lauk. Apabila satu citra mengandung lebih dari satu objek dari kelas yang sama, setiap objek dibuat sebagai anotasi yang terpisah. Sebagai contoh, dua perkedel pada satu piring dianotasi menggunakan dua poligon dengan label perkedel sehingga keduanya tetap tercatat sebagai dua instans.

Pada tahap awal, pembuatan anotasi dibantu menggunakan fitur *AI Segment Anything* pada CVAT. Fitur ini digunakan untuk menghasilkan batas awal objek secara otomatis berdasarkan objek yang dipilih oleh anotator. Batas yang dihasilkan kemudian diperiksa dan disesuaikan apabila belum mengikuti bentuk objek dengan tepat.



Gambar 3.4: Proses pembuatan anotasi menggunakan fitur *Segment Anything* pada CVAT

Sumber: Dokumentasi pribadi

Pada tahap berikutnya, proses anotasi dilanjutkan menggunakan fitur OpenCV *Intelligent Scissors* pada CVAT. Penggunaan fitur ini dilakukan dengan menempatkan beberapa titik kendali pada batas objek. Garis di antara titik-titik tersebut dibentuk secara semi-otomatis dengan mengikuti tepian visual objek. Apabila garis yang dihasilkan belum sesuai, titik kendali ditambahkan, dipindahkan, atau dihapus hingga poligon mengikuti batas objek yang terlihat.



Gambar 3.5: Proses pembuatan anotasi menggunakan fitur OpenCV *Intelligent Scissors* pada CVAT

Sumber: Dokumentasi pribadi

Segment Anything dan *Intelligent Scissors* menggunakan mekanisme yang berbeda sehingga batas awal yang dihasilkan dapat memiliki tingkat kerincian dan ketepatan yang berbeda. Oleh karena itu, hasil dari kedua fitur tidak langsung digunakan tanpa pemeriksaan. Setiap poligon diperiksa dan, apabila diperlukan, disesuaikan secara manual dengan ketentuan yang sama. Pemeriksaan mencakup kesesuaian label kelas, ketepatan poligon terhadap batas objek yang terlihat, dan pemisahan setiap objek sebagai instans tersendiri. Dengan demikian, kedua fitur hanya berperan sebagai alat bantu pembuatan poligon, sedangkan keputusan mengenai kelas dan batas anotasi tetap ditentukan melalui pemeriksaan oleh anotator.

Hasil anotasi akhir disimpan dalam format segmentasi Ultralytics YOLO agar dapat digunakan oleh YOLO11-seg. Data anotasi tersebut selanjutnya digunakan pada tahap pembagian dataset.

3.1.1.3 Pembagian Dataset

Dataset yang telah dianotasi dibagi menjadi data pelatihan, validasi, dan pengujian agar proses pembelajaran, pemilihan model, dan evaluasi akhir menggunakan bagian data yang berbeda.

Sebanyak 133 citra dengan 613 instans dibagi menjadi 107 citra untuk data pelatihan, 13 citra untuk data validasi, dan 13 citra untuk data pengujian, atau sekitar 80%, 10%, dan 10%. Pembagian dilakukan dengan memperhatikan keterwakilan sembilan kelas penelitian pada setiap bagian dataset. Jumlah citra dan instans pada setiap bagian ditunjukkan pada Tabel 3.1.

Bagian	Jumlah citra	Persentase citra	Jumlah instans
Pelatihan	107	80,5%	495
Validasi	13	9,8%	61
Pengujian	13	9,8%	57
Total	133	100%	613

Data pelatihan digunakan dalam proses pembelajaran dan pembaruan bobot YOLO11-seg. Data validasi digunakan untuk memantau performa selama pelatihan dan membantu memilih bobot model yang digunakan. Data pengujian disimpan terpisah dan digunakan untuk mengevaluasi model terpilih pada citra yang tidak digunakan untuk memperbarui maupun memilih bobot.

Pembagian dataset dilakukan sebelum augmentasi untuk mencegah citra asli dan variasi hasil augmentasinya tersebar pada bagian dataset yang berbeda. Citra duplikat, citra yang memiliki kemiripan tinggi, atau citra yang berasal dari sumber


dasar yang sama ditempatkan pada bagian dataset yang sama untuk mengurangi risiko kebocoran data [18]. Augmentasi hanya diterapkan pada data pelatihan.

3.1.1.4 Augmentasi Data

Augmentasi diterapkan pada data pelatihan untuk menambah variasi citra yang diterima model selama proses pembelajaran. Variasi tersebut membantu model mempelajari ciri objek dalam kondisi tampilan yang berbeda dan mengurangi kecenderungan model menghafal citra tertentu [19].

Augmentasi dilakukan secara dinamis melalui *pipeline* pelatihan YOLO11-seg. Transformasi diberikan ketika citra dimuat untuk proses pelatihan sehingga tidak menghasilkan salinan citra baru yang disimpan secara permanen. Oleh karena itu, augmentasi tidak mengubah jumlah citra asli dalam dataset.

Jenis augmentasi yang digunakan mencakup variasi kecerahan dan saturasi, pergeseran *hue* dalam rentang kecil, rotasi, pergeseran posisi, perubahan skala, pembalikan horizontal, dan *mosaic*. Variasi kecerahan dan saturasi digunakan untuk memberikan variasi kondisi pencahayaan. Pergeseran *hue* dibatasi pada rentang kecil karena warna merupakan ciri penting untuk membedakan beberapa lauk, misalnya rendang, telur kari, dan sambal. Rotasi, pergeseran posisi, perubahan skala, dan pembalikan horizontal digunakan untuk memberikan variasi orientasi, letak, serta ukuran objek pada citra. Rotasi juga sesuai dengan kondisi penggunaan karena kamera mengambil citra dari arah atas sehingga lauk dapat berada pada orientasi apa pun di atas piring. Sementara itu, *mosaic* menggabungkan beberapa citra pelatihan menjadi satu citra agar model menerima susunan objek yang lebih beragam. Contoh citra pelatihan hasil augmentasi ditunjukkan pada Gambar 3.6.



Gambar 3.6: Contoh citra pelatihan hasil augmentasi

Sumber: Dokumentasi pribadi

Pada transformasi yang mengubah posisi atau ukuran objek, perubahan yang sama diterapkan pada anotasi. Dengan demikian, *segmentation mask* tetap mengikuti letak dan bentuk objek pada citra hasil augmentasi. Augmentasi tidak diterapkan secara acak pada data validasi dan pengujian agar keduanya tetap merepresentasikan citra asli saat digunakan untuk mengevaluasi model.

Parameter augmentasi yang digunakan akan disimpan bersama konfigurasi pelatihan model. Pencatatan tersebut dilakukan agar proses pelatihan dapat dijalankan kembali menggunakan pengaturan yang sama.

3.1.2 Analisis Sistem

Tahap analisis sistem dilakukan untuk menentukan kebutuhan yang diperlukan dalam pengembangan sistem *checkout* otomatis Nasi Padang. Analisis mencakup kebutuhan perangkat keras, perangkat lunak, data, dan fungsi yang harus dijalankan oleh sistem.

Perangkat keras yang diperlukan meliputi:

1. kamera *webcam* USB untuk memperoleh citra piring dari posisi tetap di atas area pengambilan citra;
2. layar sentuh sebagai antarmuka bagi pelanggan untuk memulai proses *checkout* dan melihat rincian serta total harga;
3. sistem tertanam (*embedded system*) sebagai perangkat target untuk menjalankan inferensi YOLO11-seg dan program kalkulasi harga pada penerapan sistem;
4. laptop dengan prosesor AMD Ryzen 7 4800H, GPU NVIDIA GeForce RTX 3050, dan RAM 16 GB DDR4 untuk anotasi data, pengembangan program, pengujian, serta inferensi;
5. media penyimpanan untuk menyimpan citra, anotasi, bobot model, serta hasil pengujian; dan
6. area pengambilan citra yang memungkinkan posisi kamera dipertahankan tetap dengan kondisi pencahayaan yang relatif konsisten.

Karena keterbatasan biaya perangkat keras, lingkungan sistem tertanam pada penelitian ini disimulasikan menggunakan laptop tersebut. Dengan demikian, kamera, layar sentuh, model YOLO11-seg, dan program kalkulasi harga dijalankan pada laptop sebagai pengganti perangkat target.

Perangkat lunak yang diperlukan meliputi:

1. Python sebagai bahasa pemrograman utama untuk pengolahan data, pelatihan model, dan pengembangan program;

2. Ultralytics sebagai *framework* yang digunakan untuk pelatihan, validasi, pengujian, dan inferensi YOLO11-seg;
3. CVAT sebagai perangkat anotasi kelas dan poligon untuk setiap instans objek makanan;
4. Google Colab sebagai lingkungan komputasi berbasis *cloud* untuk menjalankan program *crawler*;
5. Qt/QML untuk membangun antarmuka pengguna pada layar sentuh; dan
6. pustaka pendukung yang diperlukan untuk pengolahan citra, pengelolaan dataset, serta implementasi program kalkulasi harga.

Data utama yang dibutuhkan berupa citra Nasi Padang beserta anotasi poligon dan label kelas untuk setiap instans. Sistem juga memerlukan tabel harga tetap yang memuat pasangan antara kelas makanan dan harga satuan.

Secara fungsional, sistem harus mampu menerima citra dari kamera, menghasilkan prediksi kelas dan *segmentation mask* untuk setiap instans, menghitung jumlah instans berdasarkan kelas, mencocokkan hasil tersebut dengan tabel harga, serta menghitung subtotal dan total harga. Spesifikasi perangkat dan versi perangkat lunak yang digunakan dicatat sebagai bagian dari konfigurasi pelatihan, inferensi, dan pengujian.

3.1.3 Perancangan Sistem

Tahap perancangan sistem menjabarkan prosedur yang digunakan untuk menghasilkan model YOLO11-seg dan mengintegrasikan keluarannya ke dalam proses *checkout*. Perancangan dibagi menjadi dua bagian, yaitu rancangan pelatihan model dan rancangan proses *checkout*.

Rancangan pelatihan model menjelaskan penggunaan dataset pelatihan dan validasi untuk memperoleh bobot model yang sesuai, kemudian penggunaan data pengujian untuk evaluasi akhir. Rancangan proses *checkout* menjelaskan alur

pengolahan citra baru mulai dari inferensi YOLO11-seg, penghitungan instans, hingga kalkulasi harga.

3.1.3.1 Rancangan Pelatihan Model

Pelatihan dilakukan menggunakan YOLO11-seg dengan bobot pralatih sebagai titik awal. Bobot tersebut selanjutnya disesuaikan terhadap sembilan kelas makanan pada dataset penelitian sehingga proses pelatihan tidak dimulai dari bobot acak.

Data pelatihan diberikan kepada model dalam bentuk citra beserta *ground truth* yang memuat label kelas dan poligon segmentasi setiap instans. Pada saat data dimuat, citra disesuaikan dengan ukuran masukan model dan dapat menerima augmentasi sesuai konfigurasi pelatihan.

Selama pelatihan, model menghasilkan prediksi yang dibandingkan dengan *ground truth* untuk memperoleh nilai *loss*. Nilai tersebut digunakan dalam proses *backpropagation* dan pembaruan bobot. Proses ini dilakukan berulang selama sejumlah *epoch* yang ditetapkan pada tahap implementasi.

Data validasi digunakan selama pelatihan untuk memantau perkembangan performa model tanpa digunakan untuk memperbarui bobot. Hasil validasi digunakan sebagai dasar pemilihan bobot model yang selanjutnya digunakan pada evaluasi akhir.

Model terpilih kemudian dievaluasi menggunakan data pengujian yang tidak digunakan untuk pembaruan maupun pemilihan bobot. Evaluasi dilakukan terhadap kemampuan model dalam mendeteksi, mengklasifikasikan, membentuk *segmentation mask*, serta menghasilkan jumlah instans yang sesuai dengan *ground truth*. Varian YOLO11-seg, ukuran masukan, jumlah *epoch*, *batch size*, dan konfigurasi pelatihan lainnya dicatat sesuai implementasi yang benar-benar digunakan.

3.1.3.2 Rancangan Proses *Checkout*

Proses *checkout* dimulai ketika piring yang berisi makanan ditempatkan pada area pengambilan citra. Kamera pada posisi tetap di atas area tersebut memperoleh citra piring dalam kondisi pencahayaan yang relatif terkontrol. Citra kemudian diberikan kepada model YOLO11-seg yang telah melalui proses pelatihan.

Pada tahap inferensi, YOLO11-seg menghasilkan prediksi untuk setiap instans objek makanan. Setiap prediksi akhir memuat informasi kelas, lokasi objek, nilai kepercayaan, dan *segmentation mask*. Prediksi yang memenuhi ketentuan penyaringan pada implementasi dipertahankan sebagai hasil pengenalan.

Label kelas digunakan untuk menentukan jenis makanan, sedangkan setiap prediksi akhir yang dipertahankan diperlakukan sebagai satu instans. Apabila terdapat lebih dari satu instans dari kelas yang sama, seluruh instans tersebut dihitung dan dikelompokkan berdasarkan kelasnya.

Sistem dirancang dengan asumsi pelanggan tidak sengaja menyembunyikan atau menumpuk lauk untuk menghindari penghitungan; tumpang tindih alami antar lauk tetap menjadi keterbatasan yang dievaluasi.

Hasil penghitungan diteruskan ke program kalkulasi harga. Program menggunakan tabel harga tetap yang memuat pasangan antara kelas makanan dan harga satuan. Tabel harga hanya digunakan sebagai rujukan untuk mencari harga satuan berdasarkan label kelas dan tidak termasuk dalam proses pengolahan citra. Subtotal setiap kelas dihitung dengan mengalikan jumlah instans yang dikenali dengan harga kelas tersebut, kemudian seluruh subtotal dijumlahkan untuk memperoleh total harga.

Informasi yang dihasilkan pada proses *checkout* terdiri atas kelas makanan yang dikenali, jumlah instans pada setiap kelas, harga satuan, subtotal setiap kelas, dan total harga keseluruhan. *Segmentation mask* digunakan untuk merepresentasikan wilayah setiap instans dan tidak digunakan untuk memperkirakan berat, volume, ukuran porsi, luas porsi, maupun kandungan gizi.

Sistem dirancang sebagai *proof-of-concept* proses *checkout* otomatis dan tidak mencakup pembayaran elektronik maupun pencetakan bukti pembayaran.

Bibliografi

- [1] W. Min, S. Jiang, L. Liu, Y. Rui, and R. Jain, "A survey on food computing," *ACM Computing Surveys*, vol. 52, no. 5, pp. 1–36, 2019.
- [2] K. He, G. Gkioxari, P. Dollár, and R. Girshick, "Mask R-CNN," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. IEEE, 2017, pp. 2961–2969.
- [3] Q. Guo, Y. Chen, Y. Yao, J. Ma, and T. Zhang, "A real-time chinese food auto billing system based on instance segmentation," in *2023 IEEE Region 10 Symposium (TENSYP)*. IEEE, 2023, pp. 1–5.
- [4] H.-T. Nguyen, C.-W. Ngo, and W.-K. Chan, "Sibnet: Food instance counting and segmentation," *Pattern Recognition*, vol. 124, p. 108470, 2022.
- [5] H.-T. Nguyen, Y. Cao, C.-W. Ngo, and W.-K. Chan, "Foodmask: Real-time food instance counting, segmentation and recognition," *Pattern Recognition*, 2023.
- [6] R. Khanam and M. Hussain, "Yolov11: An overview of the key architectural enhancements," *arXiv preprint arXiv:2410.17725*, 2024.
- [7] Z. Qiu, X. Huang, Z. Sun, S. Li, and J. Wang, "Gs-yolo-seg: A lightweight instance segmentation method for low-grade graphite ore sorting based on improved yolo11-seg," *Sustainability*, vol. 17, no. 12, p. 5663, 2025.
- [8] E. Aguilar, B. Remeseiro, M. Bolaños, and P. Radeva, "Grab, pay and eat: Semantic food detection for smart restaurants," *arXiv preprint arXiv:1711.05128*, 2017.

- [9] M.-Y. Wu, J.-H. Lee, and C.-Y. Hsueh, "A framework of visual checkout system using convolutional neural networks for bento buffet," *Sensors*, vol. 21, no. 8, p. 2627, 2021.
- [10] N. Aditama and R. Munir, "Indonesian street food calorie estimation using mask r-cnn and multiple linear regression," in *2022 Second International Conference on Power, Control and Computing Technologies (ICPC2T)*. IEEE, 2022, pp. 1–6.
- [11] P. Yeoh, "Iconic dishes: Your ultimate guide to nasi padang," <https://guide.michelin.com/ae-az/en/article/features/ultimate-guide-to-nasi-padang>, Oct. 2024, mICHELIN Guide, diakses 29 Agustus 2026.
- [12] I. Wahyudi, "Kenikmatan nasi padang yang membuat lidah bergoyang," <https://sumbar.antaranews.com/berita/188480/kenikmatan-nasi-padang-yang-membuat-lidah-bergoyang>, Oct. 2016, aNTARA Sumatera Barat, diakses 29 Agustus 2026.
- [13] A. M. Hafiz and G. M. Bhat, "A survey on instance segmentation: State of the art," *International Journal of Multimedia Information Retrieval*, vol. 9, no. 3, pp. 171–189, 2020.
- [14] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, "Feature pyramid networks for object detection," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2017, pp. 936–944.
- [15] D. Bolya, C. Zhou, F. Xiao, and Y. J. Lee, "Yolact: Real-time instance segmentation," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, 2019, pp. 9157–9166.
- [16] X. Yue, K. Qi, X. Na, Y. Zhang, Y. Liu, and C. Liu, "Improved yolov8-seg network for instance segmentation of healthy and diseased tomato plants in the growth stage," *Agriculture*, vol. 13, no. 8, p. 1643, 2023.

- [17] N. H. Syafira, S. A. Khoerunisa, D. N. P. Cantika, and Junervin, "A deep learning approach for real-time segmentation of graphene layers using the yolo11-seg architecture," *Proceedings of the 1st International Conference on Business, Innovation, Technology & Science*, 2025.
- [18] I. E. Tampu, A. Eklund, and N. Haj-Hosseini, "Inflation of test accuracy due to data leakage in deep learning-based classification of OCT images," *Scientific Data*, vol. 9, no. 1, p. 580, 2022.
- [19] S. Yang, W. Xiao, M. Zhang, S. Guo, J. Zhao, and F. Shen, "Image data augmentation for deep learning: A survey," *arXiv preprint arXiv:2204.08610*, 2022. [Online]. Available: <https://arxiv.org/abs/2204.08610>